LS-NEQ · ENDPUNKT 6 · BERICHT

Die umgekehrte Wirkung der Entropie-Richtung

Pythia-160m, Checkpoint step98000, Lauf 1 (Stufe C, Commit `a018239`) · Stand 28.10.2026

Kurzfassung

- **Erwartet:** Ein kleiner Schritt entlang der Entropie-Richtung `ent` macht das richtige nächste Wort wahrscheinlicher, so wie am Zustand State 2143, an dem die Richtung berechnet wurde.
- **Gefunden:** In den Testfamilien macht `ent` das richtige Wort *unwahrscheinlicher*, bei allen 7 Dosen und in allen 288 Testvarianten. Die umgedrehte Richtung hilft. Bei der Dosis 0,05 ist der präregistrierte Kontrast S6 = −0,234 [−0,299; −0,173].
- **Kein Vorzeichenfehler:** Derselbe Lauf mit demselben Vektor zeigt am State 2143 selbst den erwarteten Nutzen (B = +1,35 bei Dosis 0,05).
- **Hängt es am State?** Wahrscheinlich ja, und zwar vor allem über eine messbare Größe statt über eine Eigenheit dieses einen Texts: wie überraschend das Zielwort im Vergleich zur Entropie der Vorhersage ist. Am State 2143 ist das Zielwort extrem unwahrscheinlich (Rang ≈ 6 700), in den Testfamilien steht es an der Spitze. Eine Temperaturerhöhung macht die Verteilung flacher und hilft dabei nur Wörtern, die überraschender sind als die Verteilung im Mittel. `ent` verhält sich weitgehend so: Bei ε = 0,01 gewinnen alle 16 Varianten, deren Zielwort überraschender ist als die Entropie, und fast keine andere. Ein zustandsspezifischer Rest ist nicht ausgeschlossen.
- **Bedeutung:** `ent` überträgt sich als Entropie-Richtung, denn die Entropie steigt überall. Ihr Nutzen überträgt sich nicht. Endpunkt 6 hat den Transfer in einem Bereich getestet, in dem die hier nachträglich vorgeschlagene Erklärung das umgekehrte Vorzeichen erwarten lässt.

1. Worum es geht

1.1 State 2143 und das Dossier

State 2143 ist ein einzelner Trainingskontext von Pythia: Sequenz 5 025 183 des vorgemischten Pile-Datensatzes, davon die ersten 208 Tokens. Es ist ein englischer, wissenschaftlicher Text über Kafka mit Anmerkungen zu Werner Kraft, den Tiergeschichten, „Josefine“ und Brecht. Er endet mit „… Brecht's *Dream of Fewkoom*“. Im Training folgt „bey the Soldier“; das Zielwort ist also „bey“, das den Namen „Fewkoombey“ vervollständigt. Für das Modell ist dieses Wort extrem unwahrscheinlich: ln p = −13,60, etwa Rang 6 700 von 50 304 Tokens. Sein Favorit ist das Zeichen „_“. Die Entropie der Vorhersage ist mit 2,93 nats niedrig.

Das Forschungsdossier „State 2143“ vom 25.10.2026 beschreibt dafür einen reproduzierbaren Effekt: Ein einziger kleiner Schritt entlang des Entropie-Gradienten am Eingang des letzten Blocks (Layer 11) an der letzten Position macht „bey“ wahrscheinlicher, bei den Checkpoints step98000 und step99000. Laut den Tabellen des Vorläuferprogramms auf Drive wurde State 2143 dort wegen dieses Nutzens ausgewählt, allerdings in einem Lauf mit Pythia-70M. Das Dossier selbst liegt weder im Repository noch auf Drive; LS-NEQ stützt sich auf die Angaben in `docs/DESIGN.md` und `README.md`.

1.2 Die Richtung `ent`

`ent` ist der Gradient der Entropie der nächsten Vorhersage nach dem Zustand h_{207} (Eingang Block 11, Position 207), auf Länge 1 normiert: die Richtung, in der die Entropie am schnellsten steigt. Sie wird einmal am State 2143 berechnet und dann unverändert in jede Variante eingespeist, jeweils an der gleichen Stelle (Eingang Block 11, letzte Position der Variante). Die Dosis ist relativ: Der Eingriff hat die Länge ε mal die Norm des Zustands. Es ist der rohe Gradient. Die in `docs/DESIGN.md` vorgesehene Variante, bei der zusätzlich eine weitere Achse (die „ARI-Achse“) herausprojiziert wird, war nicht möglich, weil die Datei dafür (`data/s4/axes.npz`) fehlt.

1.3 Die Messgröße B

$$B = \ln p_\delta(\text{Zielwort}) - \ln p_0(\text{Zielwort})$$

B gibt an, wie stark der Eingriff die Log-Wahrscheinlichkeit des richtigen nächsten Wortes ändert, in nats und gemessen gegen die ungestörte Variante selbst. $B > 0$ heißt: Der Eingriff hilft dem Zielwort. B misst keinen Sprachwechsel; dafür hat LS-NEQ ein eigenes Maß, den deutschen Anteil f_D in erzeugtem Text.

1.4 Endpunkt 6

Präregistriert ist (Abschnitt 3, Punkt 6): „Transfer: B(x) mit `ent` (aus State 2143) vs. 32 Zufallsrichtungen auf Testfamilien.“ Gemessen wird je Variante

$$S6 = B(\texttt{ent}) - \text{Mittel von B über 32 Zufallsrichtungen gleicher Länge,}$$

dann das Familienmittel über die 288 Testvarianten (Familien F01–F12, Formulierungen A und B, je 12 Varianten mit K = 0 bis 28 Sprachwechseln), mit 95-%-Intervall aus 10 000 Bootstrap-Ziehungen über Familien. Jede Familie hat ein festes Zielwort nach einem gemeinsamen englischen Schlussteil, zum Beispiel „ ticket“ bei F01A.

Der präregistrierte Text nennt kein Vorzeichen. Dass einseitig im „State-2143-Vorzeichen“ (+1) getestet wird, wurde am 27.10.2026 als Nachtrag 6.6 festgelegt, als Lauf 1 die Umkehr bereits zeigte. Diese Festlegung konnte die Hypothese also nicht begünstigen; sie wirkt gegen sie (siehe Abschnitt 5).

2. Was herauskam

Dosis ε	S6 mit + `ent`	95-%-KI	S6 mit − `ent`	95-%-KI	B der Zufallsrichtungen (+)	B(+ `ent`) am State 2143
0,001	−0,004	[−0,005; −0,003]	+0,004	[0,003; 0,005]	0,000	+0,037
0,0025	−0,010	[−0,013; −0,007]	+0,010	[0,007; 0,013]	0,000	+0,092
0,005	−0,020	[−0,026; −0,015]	+0,020	[0,015; 0,025]	0,000	+0,181
0,01	−0,042	[−0,053; −0,031]	+0,039	[0,029; 0,050]	0,000	+0,351
0,02	−0,086	[−0,110; −0,063]	+0,076	[0,055; 0,097]	−0,002	+0,659
0,05	−0,234	[−0,299; −0,173]	+0,172	[0,124; 0,223]	−0,009	+1,345
0,1	−0,525	[−0,659; −0,396]	+0,290	[0,204; 0,384]	−0,035	+1,961

Tabelle 1. Endpunkt 6 auf den Testfamilien (Familienmittel, 288 Varianten, 12 Familien) und derselbe Eingriff am State 2143. Alle Werte in nats.

- Bei allen 7 Dosen ist S6 negativ, mit engen Intervallen, und zwar in jeder einzelnen der 288 Testvarianten. Die umgedrehte Richtung liefert das Spiegelbild.

- Die Zufallsrichtungen ändern B kaum. S6 kommt also ganz aus B(`ent`).
- Bei kleinen Dosen ist die Wirkung linear und spiegelsymmetrisch im Vorzeichen, etwa −4,0 nats pro Einheit ε. Hinzu kommt für beide Vorzeichen ein gemeinsamer Verlust, der mit ε² wächst (etwa −12,5·ε²): ab ε ≈ 0,02 sichtbar, bei ε = 0,1 rund −0,12 nats. Deshalb ist +`ent` bei großen Dosen stärker negativ, als −`ent` positiv ist.
- Die Entropie steigt unter +`ent` in allen 288 Testvarianten (Tabelle 2), so wie am State 2143. Die Richtung tut also, wofür sie gebaut ist.

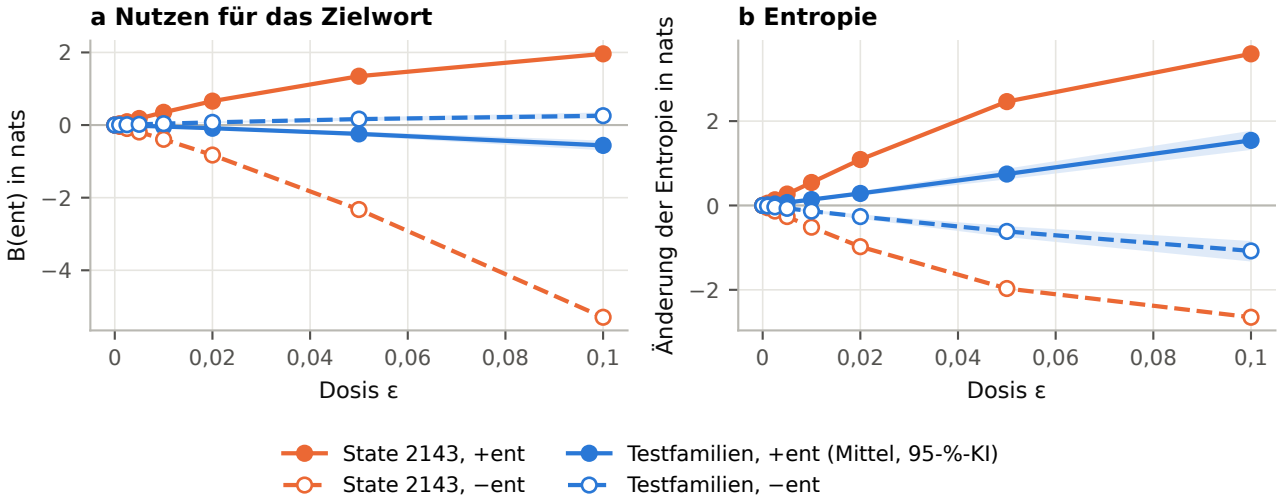


Abbildung 1. Dieselbe Richtung, entgegengesetzter Nutzen. (a) B(`ent`) am State 2143 (orange) und im Mittel der Testfamilien (blau, Band = 95-%-KI), für +`ent` (gefüllt) und –`ent` (offen, gestrichelt). (b) Änderung der Entropie der Vorhersage. In beiden Fällen hebt +`ent` die Entropie; nur am State 2143 nützt das dem Zielwort.

Dosis ε	State 2143: Entropie	State 2143: B	Testfamilien: Entropie [95-%-KI]	Testfamilien: B [95-%-KI]
0,01	+0,54	+0,35	+0,14 [0,11; 0,17]	−0,04 [−0,05; −0,03]
0,05	+2,46	+1,35	+0,74 [0,62; 0,87]	−0,24 [−0,31; −0,18]
0,10	+3,60	+1,96	+1,54 [1,32; 1,77]	−0,56 [−0,70; −0,43]

Tabelle 2. Änderung der Entropie und Nutzen B unter +`ent`, in nats.

3. Hängt das am untersuchten State?

3.1 Derselbe Lauf zeigt den Nutzen am State 2143

Die State-2143-Zeilen stehen in denselben Tabellen von Stufe C, berechnet mit demselben Vektor und demselben Code. Dort hilft +`ent` bei allen 7 Dosen, zum Beispiel B = +0,35 bei ε = 0,01 und +1,35 bei ε = 0,05. Gegen die Streuung der 32 Zufallsrichtungen ist das bei ε = 0,05 ein Ausschlag von z = +8,3 (bei ε = 0,01: z = +10,8). Auch die Fassungen des Originaltexts mit deutschen Einheiten (K = 2, 4, 5) behalten den Nutzen (S6 zwischen +1,31 und +1,49 bei ε = 0,05). Die umgedrehte Richtung schadet dort stark (B = −2,33 bei ε = 0,05). Die Dossier-Beobachtung ist damit in LS-NEQ qualitativ reproduziert, bei step98000 und mit dem rohen Gradienten; step99000 und die Variante mit herausprojizierter Achse stehen aus.

3.2 In den Testdaten ist die Umkehr ausnahmslos

Die Umkehr zeigt sich in jeder Aufschlüsselung: bei jedem K, in jeder Zelle C1, C2, C3 und seg, in beiden Formulierungen und in allen 12 Testfamilien, ebenso in den Entwicklungsfamilien und den übrigen Familien (Abbildung 2). Über alle 1 152 Standardvarianten ist S6 bei ε = 0,05 in 99,4 % negativ. Positiv sind nur 7 Varianten, 5 davon in DEV01B und 2 in F19B, keine in den Testfamilien.

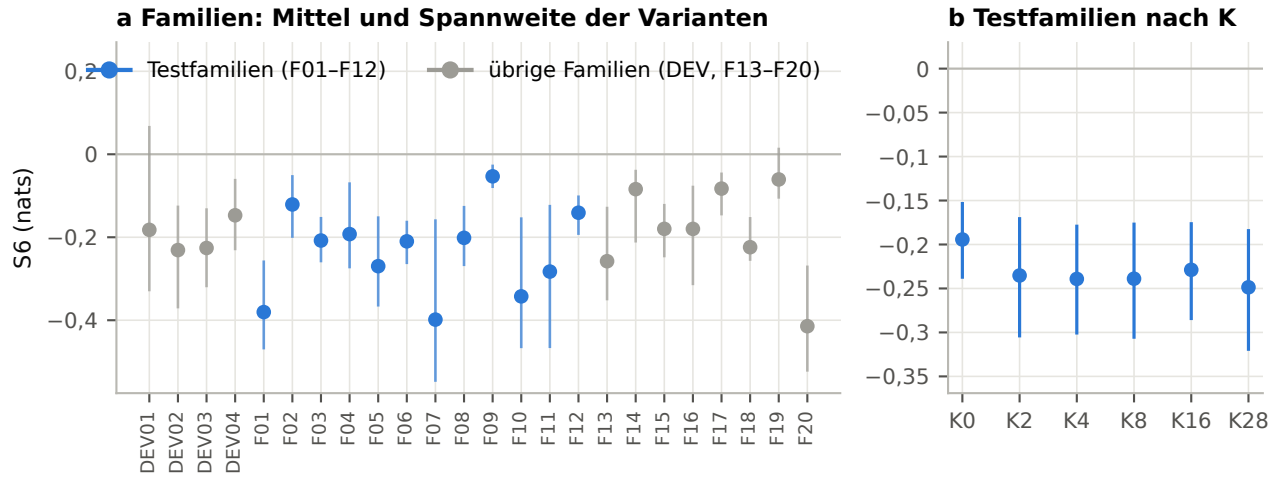


Abbildung 2. Aufschlüsselung bei ε = 0,05. (a) Familienmittel von S6 über alle vier Formulierungen, mit der Spannweite der einzelnen Varianten; die Testdaten bestehen nur aus den Formulierungen A und B. (b) Testfamilien nach Zahl der Sprachwechsel K, mit 95-%-KI. Der Betrag schwankt zwischen den Familien stark (bei F01–F12 über alle vier Formulierungen etwa um das 7,5-Fache, in den Testdaten etwa um das Neunfache), das Vorzeichen nicht.

3.3 Der Unterschied liegt beim Zielwort

Bei einer reinen Temperaturerhöhung wird die Verteilung über das nächste Wort flacher: Wahrscheinliche Wörter verlieren, unwahrscheinliche gewinnen. Für eine kleine Erhöhung gilt exakt: Die Log-Wahrscheinlichkeit eines Wortes steigt genau dann, wenn seine Überraschung $s = -\ln p$ größer ist als die Entropie H, also als die mittlere Überraschung der Verteilung:

$$\mathrm{d} \ln p / \mathrm{d}T = s - H \quad \text{(bei Temperatur } T = 1\text{)}$$

Für andere Arten, die Entropie zu erhöhen, gilt diese Grenze nicht allgemein. Ob `ent` wie eine Temperaturänderung wirkt, ist deshalb eine Arbeitshypothese. Die Daten in Abschnitt 3.4 sprechen weitgehend dafür, aber nicht ausnahmslos.

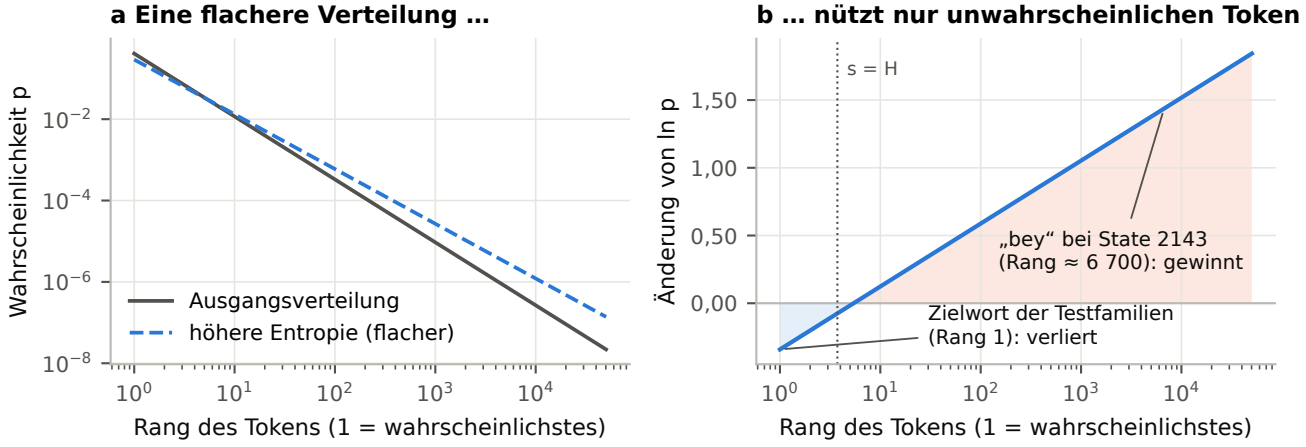


Abbildung 3. Das Prinzip (schematisch). Eine Zipf-Verteilung über 50 304 Tokens mit derselben Entropie wie am State 2143 (2,93 nats) bei leicht erhöhter Temperatur. (a) Die Verteilung wird flacher. (b) In erster Ordnung gewinnen nur Tokens, deren Überraschung die Entropie übersteigt; die Grenze s = H liegt hier bei etwa Rang 4. Bei der gezeigten endlichen Erhöhung auf T = 1,15 gewinnen die Tokens ab Rang 6. Die Rangangaben für die beiden Zielwörter stammen aus den Daten, die Kurve ist ein Schema.

Am State 2143 ist s = 13,60 und H = 2,93, also s − H = +10,67 nats: „bey“ gewinnt. In den Testfamilien steht das Zielwort in allen 288 Testvarianten an der Spitze der Verteilung, und $s - H_0$ liegt zwischen −4,11 und −0,30 nats (Median $\ln p_0 = -1{,}01$, Median $H_0 = 4{,}12$): Das Zielwort verliert überall.

3.4 Was dafür spricht

- Die einfache Regel „Gewinn genau dann, wenn $s > H_0$“ trifft bei $\varepsilon = 0{,}01$ alle 16 Varianten mit $s > H_0$: den State 2143 in vier Fassungen und 12 Varianten von DEV01B. Alle 16 gewinnen. Daneben gewinnen nur 8 Varianten von F19B, und zwar kaum messbar (höchstens 0,01 nats). Bei $\varepsilon = 0{,}05$ gewinnen von den 16 nur noch 10. Die Trefferquote über alle 1 156 Varianten (99,3 % bei $\varepsilon = 0{,}01$) sagt für sich wenig, weil fast alle Varianten verlieren; schon die Vorhersage „immer Verlust“ käme auf 97,9 %.
- **Der schärfste Einzeltest steckt in DEV01:** Alle vier Formulierungen dieser Familie haben dasselbe Zielwort „bark“. Bei $\varepsilon = 0{,}01$ gewinnt es in allen 12 Varianten der Formulierung B, in denen $s - H_0 > 0$ ist, und in keiner der 36 Varianten der Formulierungen A, C und D, in denen $s - H_0 < 0$ ist. Dasselbe Wort, verschiedene Kontexte: Über das Vorzeichen entscheidet die Lage des Worts in der Verteilung, nicht das Wort selbst.
- Je Variante hängt S6 deutlich mit $s - H_0$ zusammen ($\varepsilon = 0{,}05$; Korrelation 0,68 in den Testvarianten, 0,66 über alle 1 152 Standardvarianten). Die Wahrscheinlichkeit des Zielworts allein sagt S6 dagegen nicht voraus (Korrelation 0,01 über alle Standardvarianten).
- Die an die 288 Testvarianten angepasste Gerade ($\varepsilon = 0{,}05$: $S6 = -0{,}001 + 0{,}089 \cdot (s - H_0)$) erreicht verlängert die Null bei $s - H_0 \approx 0$ und sagt am State 2143 +0,95 voraus; beobachtet ist S6 = +1,36 (B allein +1,35). Die Gerade über alle 1 152 Standardvarianten sagt +0,81 voraus. Das Vorzeichen stimmt, der Betrag wird unterschätzt, und die Verlängerung reicht rund 11 nats über die Testdaten hinaus.
- In den 12 Varianten von DEV01B ist S6 erst ab $s - H_0 \approx 0{,}74$ positiv (5 Varianten), obwohl B(+`ent`) dort bei $\varepsilon = 0{,}01$ überall positiv ist: Auch die Zufallsrichtungen nützen diesen Zielwörtern ein wenig.
- Auch dass der Verlust bei $K > 0$ etwas größer ist als bei $K = 0$ (Abbildung 2b), passt dazu: Sprachwechsel erhöhen in den Testvarianten die Entropie im Mittel um 0,76 nats, die Überraschung des Zielworts aber nur um 0,28 nats. $s - H_0$ sinkt damit um 0,48 nats; die gepaarten Änderungen korrelieren mit der Änderung von S6 zu 0,85.
- Gegenprobe mit der Häufigkeitsachse `freq`, die häufige Tokens hebt und die Entropie senkt: Bei $\varepsilon = 0{,}05$ hilft sie den Testzielwörtern gegenüber Zufall leicht (+0,04 [0,01; 0,08]; bei $\varepsilon = 0{,}1$ nicht mehr nachweisbar) und schadet „bey“ (−1,11). Das passt zur Erklärung, trennt sie aber nicht von einer Erklärung über die Korpushäufigkeit des Zielworts; dafür ist das „bark“-Beispiel aussagekräftiger.

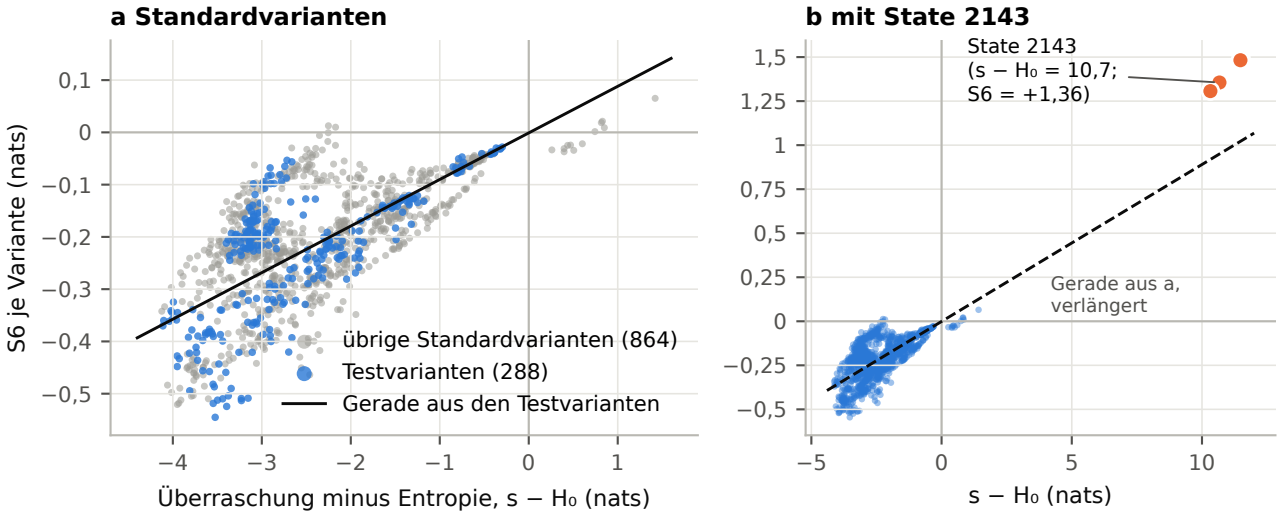


Abbildung 4. Der Effekt folgt dem Abstand zwischen Überraschung und Entropie (ε = 0,05, + `ent`). (a) Jeder Punkt ist eine Standardvariante; $s - H_0 > 0$ heißt: Das Zielwort ist im Kontext unwahrscheinlicher, als es der mittleren Überraschung entspricht. Die Gerade ist an die Testvarianten angepasst. (b) Dieselben Punkte mit dem State 2143 und seinen drei Fassungen mit deutschen Einheiten (orange). Die aus (a) verlängerte Gerade liegt auf der richtigen Seite, unterschätzt aber den Betrag.

3.5 Antwort

Wahrscheinlich ja, und zwar vor allem über eine messbare Größe statt über eine Eigenheit dieses einen Texts: wie überraschend das Zielwort im Vergleich zur Entropie der Vorhersage ist. `ent` überträgt sich als Entropie-Richtung. Ihr Nutzen überträgt sich nicht, weil eine flachere Verteilung nur Zielwörtern hilft, die im Kontext überraschender sind als die Verteilung im Mittel. Am State 2143 ist das Zielwort extrem überraschend, in den Testfamilien ist es das wahrscheinlichste Wort. Weil es nur einen Ausgangszustand gibt und die Erklärung nachträglich gefunden ist, bleibt ein zustandsspezifischer Rest möglich.

4. Vorzeichenprüfung: kein Fehler gefunden

Ein perfekt gespiegeltes Ergebnis ist genau das, was ein Vorzeichenfehler erzeugen würde. Deshalb wurde die ganze Kette im Code des Laufs geprüft (Commit `a018239`):

1. `ent` ist $+\partial H/\partial h$ ohne Minuszeichen, auf Länge 1 normiert. Kein Schritt dreht die Richtung um.
2. Das Vorzeichen wird genau einmal angewandt (δ = Vorzeichen · ε · RMS(h) · `ent`/RMS(`ent`)). Das Schreib-Audit bestätigt den tatsächlich geschriebenen Vektor bis auf $4{\cdot}10^{-5}$ relativ; ein gedrehter Vektor ergäbe einen Fehler von 2.
3. B ist $\ln p_\delta - \ln p_0$; $B > 0$ heißt, das Zielwort wurde wahrscheinlicher.
4. Die Auswertung vergleicht `ent` und Zufallsrichtungen im selben Vorzeichen. Alle Zahlen von Endpunkt 6 lassen sich aus den Tabellen auf Drive exakt nachrechnen.

Entscheidend: Am State 2143 liefern derselbe Lauf, derselbe Vektor und derselbe Code bei +1 eine steigende Entropie und ein steigendes B, bei allen 7 Dosen. Ein Vorzeichenfehler bei Gradient, Dosis, Injektion oder B würde diese Zeilen mit umdrehen. Einen Fehler in der Auswertung schließen die exakte Nachrechnung (Punkt 4) und B(+`ent`) < 0 in allen 288 Testvarianten der Rohtabelle aus. Ein Vorzeichenfehler ist damit praktisch ausgeschlossen.

Nebenbei: Der Wert $B(\lambda = 0) = 13{,}60$ aus Endpunkt 11 ist eine andere Größe, nämlich der Nutzen am Ende eines Pfades in Stufe H, der gezielt die Wahrscheinlichkeit von „bey“ erhöht. Dass er $-\ln p_0 = 13{,}60$ erreicht, heißt: p(„bey“) ist dort praktisch 1. Mit `ent` hat er nichts zu tun.

5. Was das für Endpunkt 6 bedeutet

- Die Erwartung, dass der Nutzen von `ent` auf die Testfamilien übergeht (Endpunkt 6 in der einseitigen Lesart von Nachtrag 6.6), ist nicht gestützt (BH q = 1,0 bei allen Dosen). Das Ergebnis ist aber erklärbar: Endpunkt 6 hat den Transfer in einem Bereich getestet, in dem die hier nachträglich vorgeschlagene Erklärung das umgekehrte Vorzeichen erwarten lässt.
- Zweiseitig gelesen unterschiede sich `ent` klar von Zufall, nur in der schädlichen Richtung. Der präregistrierte Text legte kein Vorzeichen fest; die einseitige Lesart (+1) wurde nach Sichtung festgelegt und wirkt gegen die Hypothese.
- Belastbar ist: `ent` ist auch in fremden Texten eine Entropie-Richtung. Die Entropie steigt in 1 152 von 1 152 Standardvarianten, bei jeder Dosis. Nachträglich beobachtet und noch unabhängig zu prüfen ist: Die Wirkung auf ein Zielwort hängt deutlich mit dem Abstand zwischen dessen Überraschung und der Entropie zusammen.
- Für das Dossier heißt das: Der Nutzen am State 2143 passt im Vorzeichen zum erwartbaren Verhalten eines extrem unwahrscheinlichen Zielworts unter einer flacher werdenden Verteilung. Die verlängerte Gerade ergibt etwa 70 % des Betrags (+0,95 von +1,36); das ist nur ein grober Anhaltspunkt.

6. Einordnung in die Literatur

- **Stolfo u. a. (2024), Confidence Regulation Neurons in Language Models**, NeurIPS 2024 (arXiv:2406.16254): Sprachmodelle regeln ihre Zuversicht über „Entropie-Neuronen“, die über die Skalierung der letzten LayerNorm wie eine Temperatur wirken, und über „Token-Frequenz-Neuronen“. Das ist ein plausibler Kanal für `ent`; auch die Spiegelwirkung von `freq` passt dazu.
- **Tan u. a. (2024), Analysing the Generalisation and Reliability of Steering Vectors**, NeurIPS 2024 (arXiv:2407.12404): Die Wirkung eines Steuervektors schwankt stark zwischen Eingaben und kehrt sich bei manchen ins Gegenteil. Bei uns entscheidet der Ausgangszustand, hier die Lage des Zielworts, über das Vorzeichen.
- **Li, Li, Huang (2026), Steering Vector Fields for Context-Aware Inference-Time Control in Large Language Models**, EMNLP 2026 (arXiv:2602.01654): Ein fester Steuervektor setzt voraus, dass eine Richtung überall gleich wirkt. Die Arbeit lernt deshalb eine differenzierbare Bewertungsfunktion für das Konzept und nimmt deren lokalen Gradienten an jeder Aktivierung als Steuerrichtung. Bei uns überträgt sich die Entropie-Wirkung, nur der Nutzen nicht; eine je Familie neu berechnete Richtung bleibt trotzdem der saubere Vergleich.
- Die Beziehung $d \ln p / dT = s - H$ nutzt auch eine ganz neue Arbeit zur Prüfung von Sprachmodell-Schnittstellen (Mei u. a., 27.10.2026, arXiv:2610.36801); sie ist ein elementares Ergebnis der Softmax-Funktion.
- Bei der Literatursuche wurde keine Arbeit gefunden, die mit dem Entropie-Gradienten nach dem Residualstrom steuert oder prüft, ob ein an einem einzigen Zustand berechneter Gradient auf andere Texte übertragbar ist.

7. Nächste Tests

1. **Ziel-Regime-Kontrolle:** dieselben Varianten, aber B für Wörter auslesen, die im Kontext unwahrscheinlich sind, zum Beispiel für Tokens an Rang 1 000 oder 5 000 der Ausgangsverteilung. Vorhersage: B(+`ent`) > 0, und zwar umso stärker, je größer $s - H_0$. Das prüft die Erklärung direkt; das „bark“-Beispiel aus DEV01 ist ein erster Hinweis.

2. **Temperatur-Vergleich:** je Variante B(`ent`) mit der Änderung unter einer reinen Temperaturänderung der letzten Logits vergleichen, wobei die Temperatur so gewählt wird, dass die Entropie gleich stark steigt.
3. **Gradient je Familie:** den Entropie-Gradienten je Familie neu berechnen (in `docs/DESIGN.md` §4.3 als eigener Arm geplant, aber nicht umgesetzt), zusätzlich je Variante, und mit `ent` vergleichen.
4. **Die Konstruktion des Dossiers:** die Variante mit herausprojizierter Achse rechnen, sobald `data/s4/axes.npz` vorliegt.
5. **Weitere Checkpoints:** die State-2143-Zeilen bei step99000.
6. **Zerlegung nach Stolfo u. a.:** welcher Anteil der Wirkung über die Skalierung der letzten LayerNorm läuft (temperaturartig) und welcher direkt auf einzelne Logits.

8. Grenzen

- Ein Checkpoint (step98000) und eine Eingriffsstelle (Eingang Block 11, letzte Position).
- Die Erklärung ist nachträglich gefunden. Exakt gilt die Regel $s > H_0$ nur für eine kleine Temperaturänderung; für `ent` ist sie eine empirische Näherung (bei $\varepsilon = 0{,}01$ gewinnen alle 16 vorhergesagten Varianten, bei $\varepsilon = 0{,}05$ nur 10).
- Die Verlängerung bis zum State 2143 reicht rund 11 nats über die Testdaten hinaus (rund 9 nats über alle Standardvarianten). Unter den Standardvarianten hat nur DEV01B ein Zielwort mit $s > H_0$.
- Das Dossier selbst liegt nicht vor. Die Zahlen des Vorläuferprogramms stammen aus einem Lauf mit Pythia-70M.

Anhang: Datenquellen und Nachrechnung

- Stufe C, Lauf 1 auf Konto A (26.10.2026, 15:51 UTC, Commit `a018239`): 647 360 Gitterzeilen aus 1 156 Varianten (1 152 Standardvarianten und 4 State-2143-Varianten) × 35 Richtungen × 2 Vorzeichen × 8 Dosen. Tabellen `grid_summary.parquet` und `contrasts.parquet` im Laufordner auf Drive.
- Auswertung: `lsne/prereg_eval.py` (Endpunkt 6), endgültiger Bericht vom 28.10.2026, 07:07 UTC (`docs/RESULTS_PREREG.md`). Alle Zahlen von Endpunkt 6 wurden mit dem Bootstrap des Repositorys exakt nachgerechnet (10 000 Ziehungen, Seed 0).
- Die Analysen dieses Berichts (Aufschlüsselung, Abhängigkeit von $s - H_0$, State-2143-Zeilen) und die Abbildungen wurden aus diesen Tabellen berechnet. Rangangaben und das Top-1-Token stammen aus der Tabelle `baseline.csv` von Stufe B (Rang 6 712, nullbasiert, für „bey“; Testzielwörter auf Rang 0 in allen 288 Varianten) und aus `docs/RESULTS_RUN1.md`.