Literatur zu den Befunden von LS-NEQ

Stand: 28.10.2026. Bezug sind die Befunde aus `docs/RESULTS_PREREG.md`, `docs/RESULTS_RUN1.md` und dem Bericht zu Endpunkt 6.

So ist die Liste entstanden. Pro Befund hat ein Agent gezielt gesucht. Ein zweiter Agent hat jede Quelle unabhängig nachgeprüft: Titel, Autoren, Jahr und Erscheinungsort über arXiv, die ACL Anthology, die Seiten der Konferenzen oder, beim Beitrag von Kissane u. a., das Alignment Forum. Danach haben drei weitere Agenten jeden Eintrag inhaltlich gegen die Abstracts und, wo nötig, die Volltexte geprüft; ihre Korrekturen sind eingearbeitet. „Inhalt“ gibt wieder, was die Arbeit selbst berichtet. „Bezug“ ist unsere eigene Einschätzung, wie die Arbeit zu LS-NEQ passt; das sind Hypothesen, keine Aussagen der Autoren. Preprints sind nicht begutachtet. Abschnitt 6 sammelt Arbeiten der letzten zwei Wochen.

Die Befunde, auf die sich die Liste bezieht:

1. **Sprachwechsel und Störungsausbreitung (Primärendpunkt).** In der konfirmatorischen Zelle C1 (Wechsel an den Grenzen der Einheiten, Injektion am Block-Eingang von Layer 4 in den Punkt am Ende von Einheit 9) steigt λ entlang der Sprachachse `lang_dom` mit Sprachwechsel um etwa 0,1 pro Layer; die Zufallsrichtungen ändern sich dort nicht nachweisbar. In den Zellen C2, C3 und seg, die an einer anderen Stelle injizieren und nicht interpretiert werden, steigen die Zufallsrichtungen dagegen ebenso stark. Fast der ganze Effekt liegt im Schritt von K = 0 auf K = 2, also mit der ersten deutschen Passage. Ein weiterer Anstieg mit K ist weder gezeigt noch ausgeschlossen; deshalb ist der Primärendpunkt „offen“ (Nachtrag 6.10). Ob der Wechsel wirkt oder die Sprache unmittelbar an der Injektionsstelle, soll die Kontrolle aus Nachtrag 6.11 klären; der Lauf steht noch aus und kann auch „offen“ enden. Wichtig für den Literaturvergleich: `lang_dom` ist eine entrauschte Mittelwertdifferenz (D − E, ohne die oberste gemeinsame Hauptkomponente). An Layer 4 hat sie mit der einfachen Differenz nur den Kosinus 0,126.
2. **Umkehr der Entropie-Richtung (Endpunkt 6).** `ent` erhöht die Entropie überall, schadet dem richtigen Zielwort in den Testfamilien aber, während es am Ausgangszustand State 2143 hilft. Nach einer nachträglich gefundenen, noch zu prüfenden Erklärung hilft eine flachere Verteilung nur Zielwörtern, die im Kontext überraschender sind als die Entropie der Vorhersage.
3. **Checkpoint-Trend (explorativ, vorläufig).** Der Abstand zwischen `lang_dom` und den Zufallsrichtungen (DiD, Zelle C1, ε = 0,05) wächst über das Training von etwa 0,055 (step1000–3000) auf etwa 0,11 (step125000–143000). Das liegt vor allem daran, dass die λ-Grundlinien ohne Wechsel (K = 0) schrumpfen, entlang `lang_dom` wie entlang der Zufallsrichtungen; Δλ(`lang_dom`) selbst steigt nur von etwa 0,069 auf 0,093. Die Werte sind eine Vorschau aus 20 von 27 Checkpoints, gepoolt und ohne Intervalle (`docs/RESULTS_RUN1.md` §2.1).
4. **SAE-Transfer.** Das SAE von step143000 rekonstruiert die Aktivierungen bei step98000 mit FVU 0,198 (Grenze 0,4). Die FVU desselben SAE bei step143000 nach derselben Definition liegt nicht vor.

---

1. Störungsausbreitung, Stabilität und Dynamik über die Tiefe

Zu Befund 1 und 3.

Ferreira da Silva, Heimersheim (2026): Evidence for feature-specific error correction in LLMs. arXiv-Preprint. arXiv:2606.24964

- INHALT: Stört den Residualstrom in einem frühen Layer und misst die Änderung in einem späteren. Kandidaten für Merkmalsrichtungen (kontrastive Richtungen, gepoolt aus Begriffen, zehn Sprachen und Programmiersprachen; MELBO; SAE) reagieren empfindlicher als Mischungen aus je zwei solchen Richtungen (Exponent p > 2); Zufalls-, PCA- und Zufallsdifferenz-Richtun-

gen tun das nicht ($p \approx 2$). Gezeigt an sechs Modellen mit 1,7 bis 9 Mrd. Parametern; ein eigenes Ergebnis nur für Sprachrichtungen gibt es nicht.

- BEZUG: Methodisch das unserem Aufbau am nächsten verwandte Design (Störung früh, Messung später, Vergleich mit Zufallsrichtungen). Ihre Zufallsdifferenz-Richtungen, die die Kovarianz der Daten erben, wären eine sinnvolle Ergänzung zu unseren isotropen Zufallsrichtungen.

Finlayson, Pernice, Todd u. a. (2026): Language Model Activations Inhabit Privileged Error-Correcting Basins. arXiv-Preprint, eingereicht am 3.10.2026. arXiv:2610.04183

- INHALT: Aktivierungen liegen in anziehenden „Becken"; entlang semantischer Steuerrichtungen gibt es merkmalsspezifische Becken. Wird die Steuerstärke so gewählt, dass sie Beckengrenzen überquert, gelingt die Steuerung zwischen Sprachen besser.
- BEZUG: Eine mögliche Lesart des Sprungs bei $K = 0 \rightarrow 2$: Die erste deutsche Passage bringt den Zustand nahe an eine Beckengrenze entlang der Sprachachse, wo Störungen schneller wachsen. Das erklärte auch, warum die Zufallsrichtungen in C1 nicht reagieren.

Janiak, Karwowski, Mangat u. a. (2024): Characterizing stable regions in the residual stream of LLMs. NeurIPS 2024 Workshop SciForDL. arXiv:2409.17113

- INHALT: Der Residualstrom zerfällt in stabile Regionen. Innerhalb reagiert die Ausgabe kaum, an den Grenzen sehr empfindlich. Die Regionen fehlen bei zufälliger Initialisierung, entstehen im Training und werden mit Training und Modellgröße schärfer.
- BEZUG: Die nächste Analogie zum Checkpoint-Trend: Ohne Wechsel ($K = 0$) sinkt λ über das Training, entlang `lang_dom` ebenso wie entlang der Zufallsrichtungen; nach dem Wechsel sinkt λ entlang `lang_dom` weniger stark, deshalb wächst der Kontrast. Stabile Regionen sagen außerdem stufenartige statt gleitende Reaktionen voraus.

Fernando, Guitchounts (2026): Dynamics of the Transformer Residual Stream: Coupling Spectral Geometry to Network Topology. arXiv-Preprint. arXiv:2605.14258

- INHALT: Zerlegt die Jacobi-Matrizen der Layer vollständig in Eigenwerte. Ihr Produkt über die Layer bildet einen niedrigrangigen Engpass, der Störungen auf wenige Dimensionen bündelt; dieser Engpass ist gelernt (OLMo, Beginn gegen Ende des Trainings).
- BEZUG: Ein konkreter Folgetest: Wie stark überlappt `lang_dom` mit den führenden Singulärvektoren der Jacobi-Matrix von Layer 4 bis 12, über Checkpoints und über K?

Cowsik, Nebabu, Qi, Ganguli (2024): Geometric Dynamics of Signal Propagation Predict Trainability of Transformers. arXiv-Preprint. arXiv:2403.02579

- INHALT: Theorie zu Ordnung und Chaos über die Tiefe von Transformern bei zufälliger Initialisierung. Zwei Lyapunov-Exponenten sagen voraus, wie gut sich das Netz trainieren lässt.
- BEZUG: Die begriffliche Grundlage, λ als Lyapunov-Exponenten über die Tiefe zu lesen. Sie gilt nur bei Initialisierung, also allenfalls für die frühesten Checkpoints.

Jaca, Benedek, Török (2026): Chaos in reason: How chain-of-thought LLMs can look for an answer. arXiv-Preprint. arXiv:2607.27805

- INHALT: Jacobi-Analyse von Teilblöcken trainierter Sprachmodelle. MLP und Attention verstärken Störungen, die Normalisierung faltet sie zurück. Endliche Störungen wachsen in frühen Layern, flachen in der Mitte ab und schrumpfen spät; die Größe des gemeinsamen Kontexts verändert die Stabilität.
- BEZUG: Ein Hinweis, dass deutscher Kontext über das Attention-Routing die Verstärkung entlang der Sprachachse erhöhen könnte. Achtung: Ihre Lyapunov-Exponenten laufen über erzeugte Tokens, nicht über die Tiefe.

Islam, Villarreal, Nishino u. a. (2026): Numerical Instability and Chaos: Quantifying the Unpredictability of Large Language Models. arXiv-Preprint. arXiv:2604.13206

- INHALT: Misst, wie stark kleine Störungen über die Layer verstärkt werden. Es gibt einen frühen „Lawinen"-Effekt und eingabeabhängige Schwellen zwischen stabilem, chaotischem und

signaldominiertem Verhalten; die Schwellen verschieben sich mit der Gleitkommagenauigkeit.

- BEZUG: Eine methodische Mahnung: Der λ-Kontrast sollte über Störungsgrößen hinweg Bestand haben, bevor man ihn mechanistisch deutet. Unsere drei Dosen sind ein erster Schritt.

---

2. Mehrsprachigkeit und Sprachwechsel im Modell

Zu Befund 1.

Quirke, Heindrich, Gurnee, Nanda (2023): Training Dynamics of Contextual N-Grams in Language Models. ATTRIB-Workshop, NeurIPS 2023. arXiv:2311.00863

- INHALT: In Pythia-70M, ebenfalls auf dem Pile trainiert, entsteht früh im Training ein Neuron, das deutschen Kontext erkennt. Es steuert spätere Neuronen, die deutsche N-Gramme fortsetzen, und das Modell hängt über die späteren Checkpoints immer stärker davon ab.
- BEZUG: Gleiche Modellfamilie, gleiche Sprache, gleiche Checkpoint-Reihe. Ein Deutsch-Detektor, der einmal anspringt und dann sättigt, würde erklären, warum der Schritt zur ersten deutschen Passage fast den ganzen Effekt trägt. Direkter nächster Schritt: prüfen, ob `lang_dom` in Pythia-160m mit solchen Neuronen zusammenfällt.

Nie, Schmid, Schütze (2025): Mechanistic Understanding and Mitigation of Language Confusion in English-Centric Large Language Models. Findings of EMNLP 2025. arXiv:2505.16538

- INHALT: In englischzentrierten Modellen ist der „Verwechslungspunkt“, das erste Token in der falschen Sprache in der erzeugten Ausgabe, die kritische Stelle. Der Übergang in die Zielsprache scheitert in den letzten Layern, wo auch die entscheidenden Neuronen sitzen.
- BEZUG: Ein mechanistisches Vorbild dafür, einen Sprachwechsel an einer bestimmten Stelle Layer für Layer zu verfolgen. Bei uns bündelt sich der Effekt allerdings nicht an einer Wechselstelle, sondern im Schritt von K = 0 auf K = 2; injiziert wird in den Punkt am Ende von Einheit 9, direkt vor dem letzten Wechsel zurück ins Englische.

Chang, Tu, Bergen (2022): The Geometry of Multilingual Language Model Representations. EMNLP 2022. arXiv:2205.10964

- INHALT: In XLM-R unterscheiden sich die Sprachen vor allem in ihren Mittelwerten entlang sprachempfindlicher Achsen. Verschiebt man Repräsentationen um die Mittelwertdifferenz, sagt das Modell Tokens der anderen Sprache vorher; sprachneutrale Information liegt auf orthogonalen Achsen.
- BEZUG: Der direkte Vorläufer von Sprachachsen aus Mittelwertdifferenzen. `lang_dom` geht von der Differenz D − E aus, entfernt aber die oberste gemeinsame Hauptkomponente; an der Tiefen-Injektionsstelle (Layer 4) bleibt von der einfachen Differenz wenig übrig (Kosinus 0,126). Ein Vergleich mit der einfachen Mittelwertdifferenz liegt daher nahe.

Gurgurov, Al Ghussin, Baeumel u. a. (2026): CLaS-Bench: A Cross-Lingual Alignment and Steering Benchmark. Findings of ACL 2026. arXiv:2601.08331

- INHALT: Vergleich von Methoden zur Sprachsteuerung über 32 Sprachen. Die einfache, normierte Differenz der Sprachmittelwerte im Residualstrom schneidet in Llama-3.1-8B-Instruct am besten ab; in Aya-Expanse-8B liegen laut Anhang die Prompting-Baselines und LAPE im Mittel vorn. Sprachspezifische Struktur zeigt sich vor allem in späteren Layern.
- BEZUG: Ein Gegenstück auf der Verhaltensebene zu einer Wirkung entlang einer Sprachachse, die über die Tiefe wächst. `lang_dom` ist dagegen eine entrauschte Mittelwertdifferenz; an Layer 4 hat sie mit der einfachen Differenz nur den Kosinus 0,126.

Park, Yoon, Jun, Lee (2026): Code-Switching Reveals Language Anchoring in Multilingual LLMs. Laut arXiv Findings of EMNLP 2026. arXiv:2606.19668

- INHALT: Setzt man einzelne Wörter einer anderen Sprache in einen englischen Satz, bleiben die Repräsentationen am Englischen „verankert“ (im Mittel in 76 % der Layer). Liefert die andere Sprache den Satzrahmen, verschieben sich die Repräsentationen zu dieser Sprache, am

stärksten in den letzten rund 30 % der Layer. Das Muster folgt der Sprache des Satzrahmens, nicht Englisch als solchem (repliziert mit Spanisch und weiteren Ausgangssprachen).

- BEZUG: Ihr Design unterscheidet sich von unserem: Sie setzen einzelne Wörter in einen Fragesatz ein, bei uns wechseln ganze Einheiten (C1) oder Satzteile (C2, C3) mit ihrer eigenen Grammatik die Sprache, und ein gemeinsamer englischer Schlussabschnitt folgt. Ihre Metrik als Funktion von K würde prüfen, ob mehr Wechsel als bei K = 2 wenig hinzufügen.

Wendler, Veselovsky, Monea, West (2024): Do Llamas Work in English? On the Latent Language of Multilingual Transformers. ACL 2024. arXiv:2402.10588

- INHALT: Eine Logit-Lens-Analyse von Llama-2 findet drei Phasen: Eingaberaum, ein englischnaher Begriffsraum in den mittleren Layern, ein sprachspezifischer Ausgaberaum in den letzten Layern.
- BEZUG: Für ein englischdominantes Modell wie Pythia eine prüfbare Vorhersage für das Tiefenprofil der Ausbreitung entlang `lang_dom`: in der Mitte gedämpft, spät wieder verstärkt.

Goncharov, Kondusov, Zaytsev (2025): Language steering in latent space to mitigate unintended code-switching. AINL 2026 (laut arXiv-Kommentar). arXiv:2510.13849

- INHALT: In zwei kleinen Modellen (Qwen2.5-1.5B, Llama-3.2-1B) trennt im letzten Layer die erste Hauptkomponente der Hidden States paralleler Übersetzungen die Sprachen fast perfekt (96–100 %); in frühen Layern sind die Sprachgruppen nur locker getrennt. Steuern entlang dieser Komponente in den letzten Layern verringert ungewolltes Code-Switching stark.
- BEZUG: Stützt für die letzten Layer, die Sprachidentität als im Wesentlichen eindimensionale Achse zu behandeln. Unsere Tiefen-Injektion liegt aber in Layer 4. Ihre Hauptkomponente wäre eine Vergleichsrichtung zu `lang_dom`.

Marchisio, Ko, Bérard, Dehaze, Ruder (2024): Understanding and Mitigating Language Confusion in LLMs. EMNLP 2024. arXiv:2406.20052

- INHALT: Sprachverwechslung tritt vor allem dort auf, wo die Verteilung des nächsten Tokens flach ist; eine höhere Sampling-Temperatur verstärkt sie.
- BEZUG: Eine prüfbare Vorhersage für die Erzeugungsexperimente von LS-NEQ (deutscher Anteil f_D): Wechsel in der erzeugten Sprache sollten dort häufiger sein, wo die Entropie hoch ist.

---

3. Entropie und Zuversicht

Zu Befund 2, der Umkehr der Entropie-Richtung. Die Detailanalyse steht im eigenen Bericht zu Endpunkt 6. Kurz: B misst, wie stark der Eingriff die Wahrscheinlichkeit des richtigen nächsten Wortes ändert. `ent` erhöht überall die Entropie. Nach einer nachträglich gefundenen, noch zu prüfenden Erklärung hilft das nur Zielwörtern, die im Kontext überraschender sind als die Entropie der Vorhersage, wie „bey“ am State 2143 (Rang ≈ 6 700). In den Testfamilien steht das Zielwort an der Spitze der Verteilung und verliert.

Stolfo, Wu, Gurnee u. a. (2024): Confidence Regulation Neurons in Language Models. NeurIPS 2024. arXiv:2406.16254

- INHALT: Sprachmodelle regeln ihre Zuversicht über „Entropie-Neuronen“. Diese schreiben in einen fast wirkungslosen Unterraum der Unembedding-Matrix und wirken über die Skalierung der letzten LayerNorm wie eine Temperatur. „Token-Frequenz-Neuronen“ schieben die Ausgabe zur Häufigkeitsverteilung hin oder von ihr weg. Untersucht unter anderem an Pythia 410M und 1B; dort erklärt die LayerNorm-Skalierung nur etwa 30–40 % der Wirkung der Entropie-Neuronen (bei GPT-2, LLaMA2 7B und Phi-2 etwa 80 %).
- BEZUG: Ein plausibler Kanal für `ent`. Eine Temperaturerhöhung hilft einem Token nur, wenn es vorher überraschender war als die Verteilung im Mittel, wie das Zielwort bei State 2143. Steht

es vorne, wie in allen Testfamilien, schadet sie. Weil in Pythia nur ein Teil der Wirkung über die Temperatur läuft, ist die Temperatur-Lesart von `ent` eine Hypothese.

Tan, Chanin, Lynch u. a. (2024): Analysing the Generalisation and Reliability of Steering Vectors. NeurIPS 2024. arXiv:2407.12404

- INHALT: Wie gut sich ein Modell steuern lässt, schwankt stark zwischen Eingaben. Bei manchen Datensätzen bewirkt derselbe Vektor bei einem großen Teil der Eingaben das Gegenteil, schon innerhalb der Verteilung, aus der er stammt; die Autoren führen das oft auf eine Bevorzugung bestimmter Antwortpositionen oder -tokens zurück. Steuervektoren übertragen sich besser, wenn das ungesteuerte Verhalten in Ausgangs- und Zielsituation ähnlich ist.
- BEZUG: Ein dokumentierter Fall, in dem derselbe Steuervektor bei einem Teil der Eingaben das Gegenteil bewirkt. Bei uns hängt das Vorzeichen nach einer nachträglichen, noch zu prüfenden Erklärung vom Ausgangszustand ab (Überraschung des Zielworts gegen Entropie).

Li, Li, Huang (2026): Steering Vector Fields for Context-Aware Inference-Time Control in Large Language Models. EMNLP 2026. arXiv:2602.01654

- INHALT: Ein fester Steuervektor setzt voraus, dass eine Richtung überall gleich wirkt; ändert sich die lokal wirksame Richtung mit dem Zustand, kann die Wirkung schwach werden oder sich umkehren. Die Arbeit lernt deshalb eine differenzierbare Bewertungsfunktion für das Konzept (ein kleines MLP, trainiert auf Präferenzdaten) und nimmt deren lokalen Gradienten an jeder Aktivierung als Steuerrichtung. Wird die Richtung seltener neu berechnet, steuert sie schwächer.
- BEZUG: `ent` ist ein eingefrorener lokaler Gradient, allerdings der Entropie und nicht eines gelernten Konzepts. Nach unseren Daten behält er seine Entropie-Wirkung überall; eine je Familie neu berechnete Richtung (in `docs/DESIGN.md` §4.3 als eigener Arm geplant, aber nicht umgesetzt) bleibt trotzdem der saubere Vergleich.

Cancedda (2024): Spectral Filters, Dark Signals, and Attention Sinks. ACL 2024. arXiv:2402.09221

- INHALT: „Dunkle“ Signale am Ende des Spektrums der Unembedding-Matrix erzeugen Attention-Sinks.
- BEZUG: Richtungen im fast wirkungslosen Unterraum sind nicht wirkungslos. Einfache Diagnose: messen, wie viel von `ent`, `lang_dom` und den Zufallsrichtungen in den unteren Singulärrichtungen der Unembedding-Matrix liegt.

Park, Choe, Veitch (2024): The Linear Representation Hypothesis and the Geometry of Large Language Models. ICML 2024. arXiv:2311.03658

- INHALT: Unterscheidet zwei lineare Darstellungen eines Begriffs, eine auf der Ausgabeseite (zum Auslesen) und eine auf der Eingabeseite (zum Steuern), und verbindet sie über ein „kausales Skalarprodukt“.
- BEZUG: Hintergrund für Gradienten-Richtungen: Ein Gradient gehört zur Ausleseseite. Ihn direkt als Steuervektor zu verwenden, setzt stillschweigend die euklidische Geometrie voraus.

---

4. SAE-Transfer und Merkmalsdynamik

Zu Befund 4.

Ge, Shu, Wu u. a. (2026): Evolution of Concepts in Language Model Pre-Training. ICLR 2026. arXiv:2509.17196

- INHALT: Crosscoder über 32 Checkpoints von Pythia-160M. Die meisten Merkmale bilden sich um step1000 und ändern dabei ihre Richtung stark; danach drehen sie sich nur noch langsam weiter.
- BEZUG: Der nächste Kontext zu unserem Transfer von step143000 auf step98000: Späte Merkmale sind weitgehend geteilt und driften langsam. Nächster Schritt wäre ein Crosscoder für 98k und 143k.

Kissane, Krzyzanowski, Conmy, Nanda (2024): SAEs (usually) Transfer Between Base and Chat Models. Alignment Forum, Zwischenbericht. Beitrag

- INHALT: Eingesetzt ins Chat-Modell erreichen SAEs des Basismodells fast denselben Kreuzentropie-Verlust wie eigene Chat-SAEs (Mistral-7B, Qwen 1.5 0.5B). Die erklärte Varianz liegt aber spürbar niedriger (Mistral-7B: 60,9 % gegen 69,2 %), und beides gilt erst nach Ausschluss der Aktivierungen mit sehr großer Norm (ohne diesen Filter 32,2 % erklärte Varianz).
- BEZUG: Unsere FVU ist ein Varianzmaß und kann deshalb schlechter aussehen als die Treue im Modell. Prüfen, ob die FVU von 0,198 von Positionen mit großer Norm getrieben ist, und zusätzlich einen Einsetztest machen.

Lieberum u. a. (2024): Gemma Scope: Open Sparse Autoencoders Everywhere All At Once on Gemma 2. BlackboxNLP-Workshop 2024. arXiv:2408.05147

- INHALT: Offene SAEs für Gemma 2. SAEs des vortrainierten Modells funktionieren auch im instruktionsgetunten Modell, gemessen am Verlust fast so gut wie eigene, gemessen an der FVU etwas schlechter.
- BEZUG: FVU-Grenze (0,4) und Treue im Modell können auseinanderlaufen. Ergänzend einen Einsetztest machen (Änderung von Verlust oder KL, wenn die Rekonstruktion ins Modell eingesetzt wird).

Xu, Wang, Huang, Wang (2024): Tracking the Feature Dynamics in LLM Training: A Mechanistic Study. arXiv-Preprint. arXiv:2412.17626

- INHALT: Eine Folge von SAEs über Pythia-Checkpoints, jedes vom vorigen aus initialisiert (Methode SAE-Track). Merkmalsrichtungen driften deutlich weiter, auch wenn ihre Bedeutung schon feststeht.
- BEZUG: Ob ein Teil unserer FVU von 0,198 auf eine solche Drift zwischen step98000 und step143000 zurückgeht, ist offen: Die FVU desselben SAE bei step143000 liegt nicht vor, und ohne diese Basis lässt sich ein Transferverlust nicht vom eigenen Rekonstruktionsfehler des SAE trennen. Die Arbeit selbst prüft kein festes SAE über Checkpoints.

Suresh, Stanley, Joseph u. a. (2026): At the Edge of Understanding: Sparse Autoencoders Trace The Limits of Transformer Generalization. arXiv-Preprint. arXiv:2606.26396

- INHALT: Ungewohnte Eingaben (Tippfehler, Jailbreaks) lassen in einem SAE mehr seltene, unpassende Merkmale anspringen und erhöhen oft den Rekonstruktionsfehler; beides fasst ein „Energie“-Wert zusammen, der solche Zustände während der Inferenz anzeigt (GPT-2, Llama 3.1 8B; nur SAEs mit L1-Strafe, keine TopK-SAEs).
- BEZUG: Passt zur Lesart aus Stufe H, dass ungesteuerte Pfade den Bereich verlassen, den das SAE gut rekonstruiert. Die Arbeit untersucht aber ungewohnte Eingaben, keine Pfade im Aktivierungsraum; bei unserem TopK-SAE ist nur der Rekonstruktionsfehler-Teil ihres Signals übertragbar.

Lee, Heimersheim (2024): Investigating Sensitive Directions in GPT-2: An Improved Baseline and Comparative Analysis of SAEs. NeurIPS 2024 Workshops ATTRIB und SciForDL. arXiv:2410.12555

- INHALT: Ergebnisse von Störungsexperimenten hängen stark von der Vergleichsrichtung ab. Isotrope Zufallsrichtungen sind problematisch, weil echte Aktivierungen nicht isotrop sind; Richtungen vom Ausgangszustand zu einer anderen Aktivierung verzerren den Vergleich, weil sie den negativen Ausgangszustand enthalten. Empfohlen werden „Mischungs“-Richtungen.
- BEZUG: Spricht dafür, neben unseren isotropen Zufallsrichtungen auch Mischungs-Richtungen als Vergleich zu nehmen: die Differenz zweier kovarianzangepasster Zufallsaktivierungen oder zweier anderer echter Aktivierungen.

Mayne, Yang, Mahdi (2024): Can sparse autoencoders be used to decompose and interpret steering vectors? arXiv-Preprint. arXiv:2411.08790

- INHALT: SAEs zerlegen Steuervektoren irreführend, aus zwei Gründen: Steuervektoren liegen außerhalb der Eingabeverteilung, für die SAEs gebaut sind, und sie können bedeutsame nega-

tive Projektionen auf Merkmalsrichtungen haben, die ein SAE nicht abbilden kann.
- BEZUG: Aussagen eines SAE über Zustände abseits der Daten brauchen diesen Vorbehalt.

---

5. Trainingsdynamik bei Pythia

Zu Befund 3, dem Checkpoint-Trend. Dazu gehören auch Quirke u. a. (Abschnitt 2: ein Deutsch-Detektor entsteht früh im Training, das Modell stützt sich danach immer stärker darauf), Janiak u. a. (Abschnitt 1) und Ge u. a. (Abschnitt 4: die meisten Merkmale bilden sich um step1000).

Tao, Cheng, Xie (2026): Persistent Depth Ordering amid Shifting Block-Bypass Responses in Language Model Pretraining. arXiv-Preprint, eingereicht am 1.10.2026. arXiv:2610.01165

- INHALT: In sechs Pythia-160M-Läufen mit verschiedenen Seeds wächst zwischen step14000 und step143000 das Update, das beim Überbrücken eines Blocks fehlt (relative RMS 0,39 → 0,59). Skaliert man diese Störung in ihrer eigenen Richtung auf gleiche relative Größe, sinkt die Reaktion an der Ausgabe (JS-Divergenz) im Mittel über vier Stärken. Bei der kleinsten Stärke steigt sie dagegen; nur bei den beiden größten sinkt sie. Die Arbeit verfolgt außerdem, wie stark relative Störungen über die Tiefe abklingen, für diese Richtung gegen Zufallsrichtungen.
- BEZUG: Dasselbe Modell, mehrere Seeds. Unsere Dosen (0,01–0,1 der RMS des Zustands) liegen bei oder unter ihrer kleinsten Stufe, wo die Reaktion spät im Training eher größer ist. Ob der Befund zu unseren sinkenden λ-Grundlinien ohne Wechsel (K = 0, für `lang_dom` wie für die Zufallsrichtungen) passt, ist deshalb offen.

Chen, Beyer, Zhu, Chen (2026): Why Does Post-Training Quantization Work? arXiv-Preprint. arXiv:2609.11716

- INHALT: Fehler in den Hidden States wachsen über die Tiefe langsam, weil der neue Fehler jedes Blocks dem geerbten Fehler entgegengerichtet ist. Diese Gegenwirkung entsteht im Vortraining; in Checkpoints von Pythia-1.4B und -2.8B ist sie bei der Initialisierung nahe null und am Ende deutlich ausgeprägt.
- BEZUG: Ein Kandidat für den Mechanismus hinter den sinkenden λ-Grundlinien. Diagnose: pro Layer den Kosinus zwischen der geerbten Störung (gestörter minus ungestörter Zustand am Blockeingang) und der Änderung des Block-Updates (gestörtes minus ungestörtes Update) messen und prüfen, ob `lang_dom` nach dem Wechsel dieser Dämpfung teilweise entgeht.

Belrose, Pope, Quirke, Mallen, Fern (2024): Neural Networks Learn Statistics of Increasing Complexity. ICML 2024. arXiv:2402.04362

- INHALT: Netze lernen zuerst einfache Statistiken wie Unigramme und Bigramme, dann komplexere; gezeigt unter anderem an Pythia-Checkpoints mit mehreren Seeds.
- BEZUG: Bei step1000 kennt Pythia schon Token-Statistiken. Der frühe Kontrast könnte daher teils lexikalisch sein. Das spricht dafür, die Kontrolle aus Nachtrag 6.11 auch an frühen Checkpoints zu rechnen.

Li, Agrawal, Ghosh u. a. (2025): Tracing the Representation Geometry of Language Models from Pretraining to Post-training. NeurIPS 2025. arXiv:2509.23024

- INHALT: Spektrale Maße auf OLMo- und Pythia-Checkpoints zeigen drei Phasen: einen Kollaps während des Warm-ups, eine Ausdehnungsphase und eine späte Kompressionsphase, die die Varianz auf wenige dominante Richtungen bündelt.
- BEZUG: Eine späte Kompression könnte erklären, warum λ ohne Wechsel (K = 0) über das Training sinkt, entlang der Zufallsrichtungen wie entlang `lang_dom`. Warum λ nach dem Wechsel entlang `lang_dom` weniger stark sinkt, erklärt sie allein nicht. Achtung: Hauptanalyse am letzten Layer und letzten Token; die Phasen zeigen sich auch in mittleren Layern, gezeigt aber nur für Modelle ab 1 Mrd. Parametern.

---

6. Neueste Arbeiten (14. bis 27.10.2026)

Diese Sammlung zielt auf Arbeiten der letzten zwei Wochen. Sie sind noch nicht begutachtet und zum Teil nur an Spielzeugmodellen gezeigt, bringen aber neue Blickwinkel. Grundlage war eine Abfrage direkt bei arXiv mit exakten Einreichungsdaten am 28.10.2026: 199 Paper zu den fünf Themen, eingereicht ab dem 14.10.2026, dazu eine Websuche. Je Thema hat ein Agent alle Einträge gelesen und die nützlichsten ausgewählt. Ein zweiter Agent hat jede Auswahl gegen die Abstract-Seite und den Volltext geprüft und Überzeichnungen korrigiert. Angegeben ist das Datum der ersten Einreichung (v1).

Keine der neuen Arbeiten untersucht Sprachwechsel zusammen mit Störungsausbreitung; die Lücke aus Abschnitt 8 besteht weiter.

Zu Störungsausbreitung, λ und Checkpoint-Trend

Ostrow, Qian, Liu, Fiete: A Mathematical Theory of the Jacobian Lens. 22.10.2026. arXiv:2610.31955

- INHALT: Eine Theorie der „Jacobian Lens“, der über Kontexte und Positionsabstände gemittelten Jacobi-Matrix des Residualstroms; die Tiefe spielt die Rolle der Zeit, die Token-Position die des Raums. Unter Modellannahmen findet die Lens Richtungen, die sich wie führende Lyapunov-Moden verhalten: Kleine Störungen entlang dieser Richtungen wachsen über die Layer, bleiben über Positionen etwa gleich und sind über Kontexte konsistent. Validiert an einem Bayes-Filter und einem kleinen Transformer.
- BEZUG: Ein eng verwandter theoretischer Rahmen: Unser λ entspräche am ehesten dem Tiefenexponenten ihres illustrativen Modells. Anders als bei uns hält die Lens die Ausgabeschicht fest und mittelt über Kontexte, während wir eine endliche Störung über die Layer 5 bis 12 verfolgen. Ein Test: `lang_dom` und die Zufallsrichtungen mit den führenden Singulärrichtungen eines in Pythia-160m geschätzten, gemittelten Jacobians vergleichen.

Jones: Chaos and bifurcations in continuous language-model feedback. 20.10.2026. arXiv:2610.31692

- INHALT: Speist man die erwartete Einbettung der eigenen Vorhersage zurück, wird ein Sprachmodell zu einem dynamischen System; Temperatur und Steuerung schieben es zwischen sich wiederholendem Text und Chaos hin und her. Die Verstärkung zerfällt in die inverse Temperatur, die Streuung der Token-Einbettungen unter der Vorhersageverteilung und die Jacobi-Matrix des Netzes. Im chaotischen Bereich ändert schon eine andere Batch-Aufteilung das Ergebnis.
- BEZUG: Macht den Ausgabeteil (Softmax) zu einem eigenen Verstärker, was zu unserer Lesart der `ent`-Umkehr als Ausgabe-Effekt passt, ohne sie zu prüfen. Methodisch ein Anlass, das numerische Grundrauschen von λ bei kleinen Dosen mitzumessen.

Oh, Ahn, Yu: Reader–Writer Coupling in Transformer MLPs. 21.10.2026. arXiv:2610.29340

- INHALT: In jedem untersuchten MLP-Block gibt es einen kleinen Kern stark gekoppelter Kanäle. Wo die Initialisierung beide Vorzeichen gleich wahrscheinlich macht, ist dieser Kern fast vollständig gegenläufig: Die Ausgabe zeigt gegen die Richtung, auf die der Eingang anspricht. Das Vorzeichen steht nach wenigen Prozent des Trainings fest, die Kopplung wächst weiter; untersucht über die Checkpoints der sieben Pythia-Größen von 70M bis 6.9B. Bei Pythia-160M legt sich ein Block erst spät fest. Nebenbefund: Im Repository von Pythia-2.8B tragen die Checkpoints step54000 bis step64000 die Daten von step143000, und eine veraltete safetensors-Datei hängt an 77 Checkpoints.
- BEZUG: Ein möglicher schichtweiser Baustein von λ (nur MLP, ohne Identitätspfad) und ein Anlass zu prüfen, ob der Checkpoint-Trend mit dem späten Umbau einzelner Blöcke zusammenfällt. Praktisch: unsere Checkpoints per Prüfsumme auf Eindeutigkeit prüfen.

Yao, Boguraev, Pimentel, Mahowald: The Emergence and Sparsification of a Syntactic Circuit. 23.10.2026, laut arXiv EMNLP 2026. arXiv:2610.33299

- INHALT: Der Schaltkreis für Subjekt-Verb-Kongruenz in Pythia-1B und zehn Seeds von Pythia-410M (neun davon aus PolyPythias) entsteht früh und baut sich danach weiter um, obwohl das Verhalten stabil ist. Zwei Ausreißer-Seeds zeigen Umbrüche, die mit Sprüngen im Verlust zusammenfallen.
- BEZUG: Spricht dafür, den Checkpoint-Trend nicht ohne Weiteres als allgemeine Trainingseigenschaft zu lesen. Er sollte an weiteren Seeds von Pythia-160m (PolyPythias) geprüft werden.

Zu Sprachwechsel und der Kontrolle aus Nachtrag 6.11

Jeong, Laroza, Yoon u. a.: One Head Away from Language Confusion: Single Attention Heads Across Model Families. 18.10.2026. arXiv:2610.25026

- INHALT: In zehn von zwölf instruktionsgetunten Modellen (1–7B) führt das Abschalten eines einzelnen, per Suche gefundenen Attention-Heads deutlich häufiger dazu, dass eine Fortsetzung die erwartete Sprache verlässt, als das Abschalten jedes anderen Heads derselben Schicht. In Basismodellen ist der Effekt kleiner.
- BEZUG: Eine gleiche Suche in Pythia-160m könnte klären, ob es dort einen Head gibt, der die Sprache verfolgt. Ob $\Delta\lambda$ über ihn läuft, zeigte erst eine erneute λ-Messung bei abgeschaltetem Head.

Martins, Dunn: Where Are Language-Specific Features Represented in Multilingual LLMs? Everywhere. 18.10.2026. arXiv:2610.25505

- INHALT: In Llama 3.2 1B lässt sich die Sprache in jeder Schicht gut ablesen, nicht nur in den ersten und letzten. Ein vorangestellter Kontext in einer Sprache verschiebt die Darstellung eines mehrdeutigen Satzes zu dieser Sprache.
- BEZUG: In Analogie zum Priming-Befund könnte auch der Punkt am Ende eines deutschen Satzteils Sprachinformation aus dem vorangehenden Kontext tragen. Das hält die lokale Erklärung, die die Kontrolle aus Nachtrag 6.11 prüft, für möglich, entscheidet sie aber nicht. Ein einfacher Vortest wäre ein Sprach-Klassifikator an der Injektionsstelle bei $K = 0$ und $K > 0$.

Ding: Language Models Keep Abandoned Analyses: Residue and Adaptation after Garden-Path Sentences. 27.10.2026. arXiv:2610.36797

- INHALT: Nach Holzwegsätzen bleibt ein Rest der verworfenen Lesart, der spätere Vorhersagen beeinflusst; per Activation Patching (neun Modelle von 1,4B bis 70B) liest späterer Text diesen Rest aus den Zuständen der Nominalphrase, die vor der Auflösung berechnet wurden. In einem zweiten Experiment zu überschriebenen Aussagen zeigt ein Attention-Knockout: In sechs Modellen tragen die Positionen nach der Aussage den alten Wert weiter, in drei liest die Antwort ihn direkt. Pythia-160M zeigt auf zwei von drei Datensätzen keinen gesicherten Rest.
- BEZUG: Die Knockout-Logik ließe sich auf LS-NEQ übertragen: Blockiert man die Aufmerksamkeit späterer Positionen auf die Wechselstelle, zeigt sich, ob der Schaden über diese weitergetragen wird. Das ergänzt die Kontrolle „lokal oder Wechsel“.

Godoy Ortiz: Meaning Contracts: Local Semantic Geometry in Large Language Models. 22.10.2026. arXiv:2610.30715

- INHALT: Die rohe Kosinus-Geometrie der Satzdarstellungen ist nach Sprache geordnet (gezeigt an Llama und Qwen); erst nach Entfernen der dominanten Richtungen ordnen sich Satzpaare über ein Band von Schichten nach Bedeutung. Bei Pythia-2.8B ist diese Ordnung schwach: unter Mittelung über die Tokens in 21 % der Schichten, am letzten Token in keiner.
- BEZUG: Unser Schaden ist ein Abstand in den rohen Koordinaten. Eine Robustheitsprüfung mit Schaden nach Entfernen der dominanten Richtungen würde zeigen, ob der Wechseleffekt auch außerhalb dieser Richtungen besteht.

Ghosh, Kumar, Garg: Measurement Validity and Representation Dynamics of Confidence Signals in Large Language Models. 19.10.2026. arXiv:2610.25846

- INHALT: Ein präregistriertes Audit von Konfidenzsignalen; eine reine Oberflächen-Baseline erreicht oft dieselbe Güte wie Sonden auf internen Zuständen, und zwei von fünf Hypothesen wurden widerlegt.
- BEZUG: Ein Vorbild für eine Oberflächen-Baseline zur Kontrolle aus Nachtrag 6.11 (λ nur aus der Sprache des unmittelbaren Kontexts vorhersagen) und für die getrennte Ausweisung von präregistrierten und nachträglichen Analysen.

Zur Umkehr der Entropie-Richtung

Mei, Tian, Yuan u. a.: API-TAIL: Detecting Model Substitution in LLM APIs through Temperature-Aligned Likelihood Tails. 27.10.2026. arXiv:2610.36801

- INHALT: Ein Prüfverfahren für Sprachmodell-Schnittstellen auf Basis von „Überraschung minus Entropie“. Im Methodenteil steht, dass die Ableitung der Log-Wahrscheinlichkeit eines Tokens nach der Temperatur (Überraschung − Entropie)/T beträgt: Eine Temperaturerhöhung hebt Tokens, deren Überraschung über der Entropie liegt, und senkt die übrigen.
- BEZUG: Die Regel, mit der sich die `ent`-Umkehr erklären ließe, falls `ent` in erster Näherung wie eine Temperaturerhöhung wirkt (siehe den Bericht zu Endpunkt 6). Test: je Variante eine effektive Temperatur schätzen; Abweichungen zeigten, dass `ent` mehr tut als eine Temperaturänderung.

Komanduri, Afshar, Miller, Gao: Measuring Mechanistic Uncertainty in Large Language Models via Causal Robustness. 15.10.2026. arXiv:2610.22636

- INHALT: Misst, ab welcher Stärke eines internen Eingriffs sich eine Antwort ändert. Bei falschen und unsicheren Antworten genügt ein schwächerer Eingriff, und die Schwelle hängt mit der Entropie der Ausgabe zusammen.
- BEZUG: Ein Hinweis, die Entropie an der Injektionsstelle in der Kontrolle aus Nachtrag 6.11 als Begleitgröße mitzuführen.

Zu SAE-Transfer und Checkpoints

Ghosh, Mathai, Babu, Agarwal: Diminishing Returns of Data in Sparse Autoencoders: Functional Behavior does not Guarantee Feature Reproducibility. 14.10.2026. arXiv:2610.20680

- INHALT: Die Rekonstruktion eines SAE ist oft schon mit wenig Daten gut, während die Eins-zu-eins-Reproduzierbarkeit der Merkmale mit mehr Daten weiter steigt (Gemma-2-2B, BatchTopK: 2 % bei 5M Tokens, 29 % bei 50M); ähnlich bei Pythia-160M (Layer 6).
- BEZUG: Unsere FVU von 0,198 ist ein funktionales Maß und zeigt nicht, dass bei step98000 dieselben Merkmale vorliegen. Test: ein eigenes SAE auf step98000 trainieren und Merkmal für Merkmal mit dem SAE von step143000 abgleichen.

He, Shen, Iacob u. a.: Learning to Read Out: Unembedding Dynamics in Language Model Pretraining. 14.10.2026, laut arXiv NeurIPS 2026. arXiv:2610.21025

- INHALT: Hidden States können eine Information schon tragen, bevor die Ausgabeschicht sie ausdrückt. Ein Wörterbuch über die Checkpoints von Pythia datiert einen Umbau der Ausgabeschicht auf ein enges frühes Fenster bei 0,4–1,1 % des Trainings. Ein SAE auf den Ausgabegewichten des letzten Checkpoints versagt an frühen Checkpoints (Gewichte, nicht Aktivierungen).
- BEZUG: Über den Abschnitt step98000 bis step143000 sagt das wenig, weil der Befund sehr früh im Training liegt. Ein Crosscoder über die Aktivierungen beider Checkpoints würde die Merkmale aber direkt vergleichbar machen.

Gupta, Zhang, Jin: Many Biases, One Circuit: Post-Training Tunes a Pretrained Cue-Routing Mechanism. 16.10.2026. arXiv:2610.22937

- INHALT: Tauscht man in Tulu-3-8B und OLMo-2-7B die Attention-Muster von sechs mittleren Schichten zwischen dem RL-Checkpoint und seinem DPO-Vorgänger, rückt der Effekt von Hinweisen auf eine vorgeschlagene Antwort größtenteils auf das Niveau des jeweils anderen Checkpoints.
- BEZUG: Methodisch übertragbar: Attention-Muster zwischen step98000 und step143000 tauschen und messen, wie viel vom Checkpoint-Unterschied in Δλ mitwandert.

Etwas älter, aber ebenfalls ganz neu

In den Themenabschnitten stehen zwei Arbeiten von Anfang Oktober 2026, die direkt zu LS-NEQ passen: Finlayson u. a. (3.10.2026, Abschnitt 1: Becken im Aktivierungsraum) und Tao u. a. (1.10.2026, Abschnitt 5: In sechs Pythia-160M-Läufen ist die Ausgabereaktion auf eine gleich große relative Störung entlang der Richtung des fehlenden Block-Updates bei step143000, gemittelt über vier Stärken, kleiner als bei step14000; bei der kleinsten Stärke ist sie größer, und unsere Dosen liegen noch darunter).

---

7. Anregungen für nächste Schritte aus der Literatur

1. **Vergleichsrichtungen:** neben isotropen Zufallsrichtungen auch Mischungs-Richtungen (Differenz zweier kovarianzangepasster Zufallsaktivierungen oder zweier anderer echter Aktivierungen; Lee und Heimersheim 2024) und Zufallsdifferenz-Richtungen (Ferreira da Silva und Heimersheim 2026).
2. **Normwachstum:** Die Residualnorm wächst über die Layer; Störungen werden deshalb relativ zur Norm des ungestörten Zustands gemessen (so auch Chen u. a. 2026 und Tao u. a. 2026). Das ist bei uns schon so: D ist relativ zur Norm des ungestörten Zustands (`lsne/dynamics.py`, `DamageMap`).
3. **Störungsgröße und Genauigkeit:** den Kontrast über weitere Dosen und eine zweite Gleitkommagenauigkeit prüfen (Islam u. a. 2026; Jones 2026).
4. **Entropie-Richtung:** zuerst die Ziel-Regime-Kontrolle aus dem Bericht zu Endpunkt 6 (die Wirkung von `ent` auf im Kontext unwahrscheinliche Wörter auslesen; Vorhersage: positiv). Danach eine je Familie neu berechnete Richtung (Li u. a. 2026) und messen, wie viel von `ent` im fast wirkungslosen Unterraum der Unembedding-Matrix liegt (Stolfo u. a. 2024; Cancedda 2024).
5. **Sprachachse und Neuronen:** prüfen, ob `lang_dom` mit Deutsch-Kontext-Neuronen oder deutschen SAE-Merkmalen zusammenfällt und ob beides über die Checkpoints gemeinsam entsteht (Quirke u. a. 2023). Außerdem die einfache Mittelwertdifferenz als Vergleichsachse rechnen (Chang u. a. 2022).
6. **SAE über Checkpoints:** FVU desselben SAE bei step143000 als Basis bestimmen, dann FVU und Einsetztest als Funktion des Checkpoint-Abstands, mit und ohne Positionen großer Norm; ein Crosscoder für step98000 und step143000 (Kissane u. a. 2024; Ge u. a. 2026).
7. **Jacobi-Analyse:** Überlapp von `lang_dom` mit den führenden Singulärvektoren der Jacobi-Matrix von Layer 4 bis 12 (Fernando und Guitchounts 2026; Ostrow u. a. 2026).
8. **Seeds:** den Checkpoint-Trend an weiteren Seeds von Pythia-160m prüfen (PolyPythias; Yao u. a. 2026).
9. **Lokal oder weitergetragen:** mit Attention-Knockout prüfen, ob der Schaden über die Positionen nach der Wechselstelle weitergetragen wird (Logik aus Ding 2026); das ergänzt die Kontrolle aus Nachtrag 6.11.
10. **Checkpoints prüfen:** die geladenen Checkpoints per Prüfsumme auf Eindeutigkeit kontrollieren (Oh u. a. 2026 fanden im Repository von Pythia-2.8B falsch belegte Checkpoints: Unter step54000 bis step64000 liegen die Daten von step143000).

8. Was die Suche nicht gefunden hat

Die Agenten haben gezielt danach gesucht und nichts gefunden. Das heißt nicht sicher, dass es nichts gibt, aber diese Punkte scheinen kaum untersucht:

- Eine Arbeit, die einen Lyapunov-artigen Wachstumsexponenten über die Tiefe entlang einer Sprachachse gegen Zufallsrichtungen misst, abhängig von der Zahl der Sprachwechsel, oder so etwas entlang einer Sprachachse über Pythia-Checkpoints verfolgt. Verwandte Messungen ohne Sprachachse gibt es: Tao u. a. 2026 vergleichen in sechs Pythia-160M-Läufen bei step14000 und step143000, wie stark relative Störungen über die Tiefe abklingen, für die Richtung des fehlenden Block-Updates gegen Zufallsrichtungen; Chen u. a. 2026 verfolgen Quantisierungsfehler über die Tiefe an Checkpoints von Pythia-1.4B und -2.8B. Ferreira da Silva und Heimersheim 2026 vergleichen Merkmals- mit Zufallsrichtungen, aber ohne Wachstumsexponent, Wechsel oder Checkpoints; Fernando und Guitchounts 2026 messen Jacobi-Spektren an drei OLMo-Checkpoints.
- Eine mechanistische Studie zu deutsch-englisch gemischten Eingaben in kleinen englischdominanten Modellen. Keine Arbeit variiert die Zahl der gewechselten Einheiten oder betrachtet jede Wechselstelle einzeln über die Tiefe.
- Eine Arbeit, die mit dem Entropie-Gradienten nach dem Residualstrom steuert oder prüft, ob ein an einem Zustand berechneter Entropie-Gradient auf andere Kontexte übertragbar ist. Für den Gradienten eines gelernten Konzept-Scores zeigen Li, Li, Huang (2026, Abschnitt 3), dass eine seltener neu berechnete Richtung schwächer steuert.
- Ein veröffentlichter Test, ob ein SAE des letzten Checkpoints die Aktivierungen der Zwischen-Checkpoints desselben Modells rekonstruiert. He u. a. (2026, Abschnitt 6) tun das nur für die Gewichte der Ausgabeschicht.

Auch unter den neuesten Arbeiten (Abschnitt 6) untersucht keine Sprachwechsel zusammen mit Störungsausbreitung. Die Kombination aus kontextabhängigem λ, Richtungsspezifität und Trainingsverlauf scheint demnach neu zu sein.